

Universidad de la República — Facultad de Ingeniería
Instituto de Matemática y Estadística (IMERL)

Modelos Estadísticos para la Regresión y la Clasificación

Entrega 1
Segundo semestre 2026

Integrantes

Sebastián Guigou	C.I. _____
Francisco Scaletti	C.I. _____
Dionisio Bell	C.I. _____

Código de los tres problemas:
<https://github.com/seboongas/ModelosEst>

Montevideo, octubre de 2026

1. Estimador de máxima verosimilitud

Densidad $f(x) = \frac{1}{2}(1 + \theta x)$ en $[-1, 1]$, con $\theta = -1/3$ verdadero.

Simulación. La FDA es $F(x) = \frac{x+1}{2} + \theta \frac{x^2-1}{4}$; resolviendo $F(x) = u$ con $u \sim U(0,1)$ queda $x = (-1 + \sqrt{1 - \theta(2 - \theta - 4u)})/\theta$ (transformada inversa). El histograma de $2 \cdot 10^5$ simulaciones coincide con f (Fig. 1, izq.) y su media $(-0,114)$ con $\mathbb{E}[X] = \theta/3 = -0,111$.

Verosimilitud. $\ell(\theta) = \sum_i \log(1 + \theta x_i) - n \log 2$. Es cóncava en θ ($\ell'' = -\sum_i x_i^2/(1 + \theta x_i)^2 < 0$), por lo que tiene un único máximo y la búsqueda de la sección áurea sobre $[-1, 1]$ (implementada a mano, contrastada con `scipy.optimize.minimize_scalar`) lo encuentra. No hay fórmula cerrada para $\hat{\theta}$.




Figura 1. Simulador y verosimilitud para tres muestras de tamaño 10 (los puntos son los $\hat{\theta}$).

Con $n = 10$ el máximo cambia mucho de una muestra a otra: en la Fig. 1 salen $\hat{\theta} = -0,22, -1$ y $0,34$. Cuando la verosimilitud es monótona en $[-1, 1]$ el máximo cae en el borde ($\hat{\theta} = \pm 1$): le pasa a alrededor del 19 % de las muestras de tamaño 10.

Sesgo, varianza y MSE. Se generaron $M = 1000$ muestras por cada n (la letra sugiere ~ 50 ; con $M = 50$ y $n = 10$ el sesgo estimado fue 0,16, un artefacto del ruido de Monte Carlo, ya que su error estándar es $\approx 0,07$). Con $\text{MSE} = \text{sesgo}^2 + \text{var}$:

n	media de $\hat{\theta}$	sesgo	varianza	MSE	$n \cdot \text{var}$
10	-0,345	-0,012	0,2738	0,2739	2,74
100	-0,333	0,001	0,0279	0,0279	2,79
1000	-0,332	0,001	0,0028	0,0028	2,84




Figura 2. Distribución de $\hat{\theta}$ en $M = 1000$ muestras para cada n (la línea roja es $\theta = -1/3$).

Conclusiones. (i) El sesgo es chico en todos los casos: está dentro de un error estándar de Monte Carlo (0,017; 0,005; 0,002), así que no se distingue de cero, coherente con que el MLE es asintóticamente insesgado. (ii) La varianza baja ≈ 10 veces cada vez que n se multiplica por 10, y $n \cdot \text{var} \approx 2,8$ se acerca a $1/I(\theta) = 2,80$, con $I(\theta) = \frac{1}{2} \int_{-1}^1 \frac{x^2}{1+\theta x} dx = 0,3575$ (información de Fisher). (iii) Como el sesgo es despreciable, el MSE es prácticamente la varianza. (iv) Con $n = 10$ la distribución de $\hat{\theta}$ está lejos de la normal (acumula masa en ± 1); con $n \geq 100$ ya es aproximadamente normal y concentrada alrededor de $-1/3$.

2. Regresión en Boston Housing

Datos y exploración. Se usó el dataset **Boston** de ISLP (506 viviendas, 12 atributos y **medv**, sin valores faltantes; no trae la variable **B** del original). **medv** es asimétrica a la derecha y 16 viviendas valen exactamente 50 (valor tope, censurado). Las variables más correlacionadas con **medv** son **lstat** ($-0,74$), **rm** ($+0,70$) y **prratio** ($-0,51$); la relación con **lstat** es claramente curva, lo que motiva los polinomios.




Figura 3. Exploración inicial: distribución de MEDV y las dos relaciones más fuertes.

Metodología. Partición aleatoria 80 %/20 % (404 entrenamiento, 102 validación; semilla 42). Todos los modelos son **PolynomialFeatures** → estandarización → regresión (MCO o Ridge). λ se eligió por validación cruzada de 5 folds *dentro del entrenamiento*, de modo que la validación sólo se usa para evaluar. Grado 3 genera 454 atributos, más que las 404 observaciones.

Grado	#atrib.	MCO (sin regularizar)			Ridge (λ^* por CV)		
		MSE entr.	MSE valid.	λ^*	MSE CV	MSE entr.	MSE valid.
1	12	22,60	22,78	3,98	25,28	22,62	22,91
2	90	5,72	15,16	0,40	16,07	6,80	11,94
3	454	0,46	1175,60	1,00	18,06	4,22	10,73




Figura 4. Izq.: MSE según el grado. Centro: MSE de CV en función de λ (el punto marca el mínimo). Der.: predicho vs. real en validación para MCO de grado 2 y Ridge de grado 2.

Conclusiones.

- **Lineal (grado 1):** el MSE es parecido en entrenamiento y validación (22,6 y 22,8): no sobreajusta, pero subajusta porque la relación no es lineal.
- **Polinomios con MCO:** el grado 2 baja el MSE de validación a 15,2, pero ya con una brecha grande respecto de entrenamiento (5,7). Con grado 3 hay más atributos que datos, el modelo interpola el entrenamiento (MSE 0,46) y en validación es inutilizable (1176): sobreajuste extremo.
- **Ridge:** la penalización controla la varianza. Mejora al grado 2 (15,2 → 11,9) y rescata al grado 3 (1176 → 10,7). En grado 1 casi no cambia nada (pocos atributos, nada que penalizar).
- **Mejor modelo:** Ridge con polinomio de grado 2 y $\lambda \approx 0,4$, por tener el menor MSE de CV (16,1 contra 18,1 del grado 3), criterio que no mira la validación. En esta partición el grado 3 con Ridge dio un MSE de validación algo menor (10,7 contra 11,9), pero repitiendo con 30 particiones aleatorias la diferencia no se sostiene: medianas 11,7 (grado 2) y 12,3 (grado 3), con desvíos de 3,8 y 5,6; la del MCO de grado 3 es 1681. Con 102 datos de validación esa diferencia entra en el ruido, y el grado 2 es más simple.
- **Limitaciones:** el valor tope de 50 en **medv** hace que el modelo subestime esas viviendas (puntos abajo a la derecha en la Fig. 4), y el MSE de una sola partición es ruidoso.

3. Alturas

Datos y decisiones. 45 respuestas. Se descartaron 2: el id 36 no tiene altura propia y el id 4 no tiene sexo (quedan 43: 36 varones y 7 mujeres). La altura del estudiante depende fuertemente del sexo (media 179,2 cm en varones y 162,9 en mujeres), así que se incluyó el sexo como variable indicadora. Como hay sólo 7 mujeres, no se ajustaron pendientes distintas por sexo (interacciones): el modelo con interacciones empeora el error de validación cruzada leave-one-out (29,1 contra 21,6) y el AIC. El resto de los modelos se comparó con R^2 ajustado, AIC y ese error LOO:

Modelo para la altura del estudiante	R^2 ajust.	AIC	$\hat{\sigma}$ (cm)	ECM LOO
padre	0,02	301,1	7,84	65,8
padre + madre	0,02	302,1	7,85	67,2
sexo	0,58	264,3	5,11	28,3
padre + sexo	0,66	255,8	4,58	23,7
padre + madre + sexo	0,71	251,1	4,29	21,6
padre + madre + sexo + interacciones	0,69	254,8	4,39	29,1

Sin el sexo, las alturas de los padres no explican nada (R^2 ajustado 0,02): el sexo es lo primero que hay que incluir, y las alturas de los padres recién aportan al controlar por él.




Figura 5. Altura del estudiante contra la del padre y la de la madre (por sexo), y ajustado vs. real del modelo elegido.

Modelo elegido (MCO, $n = 43$, $\hat{\sigma} = 4,3$ cm, R^2 ajustado 0,71; residuos sin señales de apartarse de la normalidad):

$$\widehat{\text{altura}} = 74,4 + 0,278 \text{ padre} + 0,337 \text{ madre} - 17,4 \text{ mujer}$$

con alturas en cm y mujer = 1 si la persona es de sexo femenino y 0 si es masculino.

Significado de los coeficientes (IC 95 % entre corchetes):

- **Padre**, 0,28 [0,10; 0,46]: a igual altura de la madre e igual sexo, cada cm más de altura del padre se asocia con 0,28 cm más de altura del estudiante.
- **Madre**, 0,34 [0,07; 0,60]: lo mismo para la madre, a igual altura del padre e igual sexo.
- **Mujer**, -17,4 [-21,1; -13,8]: con las mismas alturas de padre y madre, las mujeres miden en promedio 17,4 cm menos que los varones.
- **Constante**, 74,4: altura esperada de un varón con padre y madre de altura 0 cm; no tiene interpretación real porque está lejos de los datos. Centrando padre y madre en sus promedios (178,5 y 164,2 cm) la constante pasa a ser 179,4 cm: la altura esperada de un varón con padres de altura promedio.

Conclusiones y advertencias. Los coeficientes de padre y madre suman $0,62 < 1$: un estudiante con padres muy altos tiende a ser alto pero menos que ellos (regresión a la media). Son asociaciones, no efectos causales. Con 43 datos los intervalos son anchos y el modelo es frágil: el id 39 (mujer de 177 cm con padre de 198 cm) tiene la mayor distancia de Cook (0,57; el umbral orientativo $4/n$ es 0,09) y, si se lo saca, el coeficiente del padre baja de 0,28 a 0,19 y R^2 ajustado sube a 0,75. Se lo dejó porque los datos son plausibles (padre muy alto) y no hay evidencia de error de carga; el id 16 (varón de 170 cm con padre de 187 cm) es el otro residuo grande. Agregar el id 4 como varón cambia el coeficiente de la madre de 0,34 a 0,17: el efecto de la madre es el menos estable. Los datos son de estudiantes de un curso, no una muestra aleatoria de la población, así que no conviene extrapolar el modelo.